



TCO-Analyse souveräne KI-Plattform versus Cloud

Gemma 4 31B im Klinik-Kontext, 8x NVIDIA RTX PRO 6000 Blackwell

Erstellt: 25. Mai 2026

Erstellt von: GREENBAY healthcare GmbH

Version: 1.1

Auslastungs-Szenario: 70 Prozent sustained

1. Management Summary

Diese Analyse beantwortet die Kernfrage, ob der Betrieb eines KI-Sprachmodells fuer klinische Anwendungen in einem eigenen Rechenzentrum (Onpremise) oder bei einem Cloud-Anbieter wirtschaftlicher ist. Untersuchungsgegenstand ist eine Plattform auf Basis des frei verfuegbaren Modells Gemma 4 31B von Google, betrieben auf einem Cluster aus acht NVIDIA RTX PRO 6000 Blackwell Grafikkarten in einem deutschen Hochsicherheits-Rechenzentrum. Verglichen werden EU-souveraene Anbieter (STACKIT, IONOS, OVHcloud), Vertex AI in der EU-Region sowie die guenstigsten US-Anbieter (DeepInfra, Together.ai).

KERNERGEBNIS BEI 70 PROZENT AUSLASTUNG (636 MRD. TOKENS PRO JAHR)

142.397 EUR vs. 470.148 EUR

KRITIS-Onpremise schlaegt STACKIT um Faktor 3,3. Drei-Jahres-Einsparung: rund 983.000 EUR. Selbst der guenstigste US-Anbieter (DeepInfra mit 120.247 EUR) bietet bei diesem Volumen keinen relevanten Preisvorteil, ist aber fuer Klinikdaten rechtlich nicht zulaessig.

Die wichtigsten Erkenntnisse

Erstens: Die direkten Schnittstellen der grossen US-Sprachmodelle (ChatGPT von OpenAI, Claude von Anthropic, Gemini von Google) sind fuer die Verarbeitung von Patienten- und Versichertendaten in Deutschland aus DSGVO-Gruenden nicht zulaessig. Die populaereste Cloud-Option faellt damit von vornherein aus dem Vergleich.

Zweitens: Bei produktiver Auslastung schlaegt der Eigenbetrieb saemtliche europaeischen Cloud-Anbieter um den Faktor drei bis fuenf. Selbst das mittlere RZ-Setup mit ISO 27001 unterbietet jeden EU-Anbieter deutlich.

Drittens: Cloud-Nutzung verursacht erhebliche Infrastrukturkosten, die in keinem Werbe-Preisblatt auftauchen. VPN, API-Gateway, Observability, FinOps, Drittlandtransfer-Pruefung, DPO-Review, KI-Haftpflicht und Personal summieren sich auf 56.900 bis 73.200 EUR pro Jahr zusaetzlich zu den reinen Tokengebuehren.

Viertens: Die Wirtschaftlichkeit haengt entscheidend von der Auslastung ab. Eine teure Hochleistungs-Anlage fuer eine einzige Anwendung lohnt sich nicht. Eine gemeinsame Plattform fuer mehrere Anwendungen (Arztbrief-Erstellung, Krankenkassen-Analytik, Forschungsauswertung, Diktat-Transkription) oder mehrere Haeuser dagegen sehr deutlich.

Strategische Konsequenz: Die ehrliche Frage lautet nicht Cloud oder Eigenbetrieb. Sie lautet: Setze ich eine einzelne Anwendung um oder baue ich eine souverae KI-Plattform fuer meine Organisation? Im zweiten Fall ist Onpremise sowohl die wirtschaftlich als auch die regulatorisch eindeutig vorteilhafte Option.

2. Methodik und Annahmen

Hardware-Setup (Referenz-Konfiguration)

Position	Wert	Anmerkung
GPU-Modell	RTX PRO 6000 Blackwell	96 GB GDDR7, Workstation-Klasse
Anzahl GPUs	8	4 Replikas mit Tensor-Parallel TP=2
GPU-Stueckpreis	9.500 EUR	Listenpreis 2026
Server-Chassis	32.000 EUR	Dual EPYC CPU, 1 TB DDR5 RAM, 8 TB NVMe, 200 GbE
Rack, USV, Kabelage	4.000 EUR	Anteilig
Stromverbrauch	4,5 kW	Sustained Last inkl. Netzteilverluste
AfA-Zeitraum	3 Jahre	Lineare Abschreibung
CapEx gesamt	112.000 EUR	AfA p.a.: 37.333 EUR

Hinweis zum Server-Chassis: Die Position deckt den kompletten GPU-Tragerserver inklusive Dual-EPYC-CPU, 1 TB DDR5 RAM, 8 TB NVMe Storage und 200 GbE Netzwerkkarte ab. Es handelt sich um einen GPU-spezifisch konfigurierten Server (PCIe Gen5 Lanes fuer acht GPUs, viel RAM fuer KV-Cache, schnelle NVMe fuer Modell-Loading), nicht um allgemeine Office-IT. Allgemeine IT-Infrastruktur (Office-Server, Mail, Active Directory, Basis-Netzwerk) wird auf beiden Seiten des Vergleichs nicht angesetzt, da sie unabhaengig vom KI-Setup ohnehin vorhanden ist. Konservativ angesetzt waeren 35.000 bis 40.000 EUR fuer ein Production-Grade-System realistisch, was die Onpremise-TCO um rund 2.700 EUR pro Jahr erhoehrt und die Gesamtaussage nicht aendert.

KI-Modell und Durchsatz

Als Referenzmodell dient Gemma 4 31B Dense von Google, veroeffentlicht im April 2026. Die Quantisierung auf NVFP4 sowie Multi-Token-Prediction-Drafter ermoeglichen einen Cluster-Peak-Durchsatz von 28.800 Tokens pro Sekunde. Ein Token entspricht ungefaehr einer Silbe oder einem kurzen Wort.

Auslastung	Tok/s sustained	Tok/Tag	Tok/Jahr (Mrd.)
10 Prozent	2.880	248.832.000	90,8
30 Prozent	8.640	746.496.000	272,5
50 Prozent	14.400	1.244.160.000	454,1
70 Prozent (Annahme)	20.160	1.741.824.000	635,8
90 Prozent	25.920	2.239.488.000	817,4

DSGVO-Ausschluss (US-Sprachmodelle)

Die direkten Schnittstellen von ChatGPT (OpenAI), Claude (Anthropic) und Gemini (Google) werden im Vergleich **nicht als Optionen** geführt. Sie sind fuer die produktive Verarbeitung von Patienten- und Versichertendaten in Deutschland aufgrund der DSGVO und der ergaenzenden Anforderungen fuer Sozialdaten praktisch nicht zulaessig. Die populaerste Cloud-Option faellt damit ohne weitere Pruefung aus dem Vergleich heraus.

Wichtige Klarstellung: Auch fuer Anbieter mit US-Mutterkonzern (AWS, Microsoft Azure, Google Cloud inklusive Vertex AI in der EU-Region) besteht ein ungeloeuster Konflikt mit dem US Cloud Act. Ein US-Gericht kann die Herausgabe von Daten anordnen, unabhaengig vom Speicherort. Eine BSI-C5-Zertifizierung loest dieses strukturelle Problem nicht.

3. Rechenzentrums- und Infrastrukturkosten

Die folgende Aufstellung zeigt die jährlichen RZ-Kosten in drei Stufen. Mittel-RZ entspricht einem ISO-27001-zertifizierten Hosting. Premium-RZ bietet zusätzlich BSI-C5-Zertifizierung und Cage-Lösungen. KRITIS-RZ ist georedundant ausgelegt und erfüllt die Anforderungen fuer kritische Infrastrukturen einschliesslich BSI C3A.

Position (EUR pro Jahr)	Mittel-RZ	Premium-RZ	KRITIS-RZ
Rack-Miete Half-Rack 24 HE	5.400	9.600	14.400
Stromkosten (4,5 kW Sustained)	11.038	11.038	11.038
Kuehlung / PUE-Aufschlag (1,3)	3.311	3.311	3.311
Netzanbindung redundant, /29 IPv4	1.800	3.600	6.000
DDoS-Schutz Layer 3/4 und 7	1.200	2.400	3.600
Eigener Cage / abschliessbares Rack	0	1.800	3.600
Remote Hands (8h inkl., dann 120 EUR/h)	600	960	1.200
Elektronikversicherung (0,4 Prozent CapEx)	448	448	448
Betriebsausfallversicherung	1.500	2.500	3.500
Cyber-Versicherung (DSGVO und Loesegeld)	2.500	3.500	5.000
KI-Haftpflicht (OLG Hamm)	3.000	5.000	8.000
NVIDIA Enterprise GPU Support (5 Prozent)	3.800	3.800	3.800
Server-Hardware NBD-Support	1.800	2.500	3.000
Hot-Spare-GPU (anteilig 3 Jahre)	3.167	3.167	3.167
Backup / Snapshot-Storage (10 J. Retention)	720	1.200	1.800
Monitoring / SIEM (extern, KRITIS-tauglich)	1.800	4.000	7.200
BSI- / ISO-Audit-Anteil	0	4.000	8.000
Personal Plattform-Ops (0,2 FTE)	18.000	18.000	18.000
Summe Infrastruktur p.a.	60.084	80.824	105.064
Hardware-AfA pro Jahr	37.333	37.333	37.333
TOTAL TCO Onpremise p.a.	97.417	118.157	142.397

Methodische Hinweise zu den Posten: Personal (18.000 EUR) ist der einzelne groesste Posten und wird in vielen Cloud-Wechsel-Argumentationen verschwiegen. Die KI-Haftpflicht ist nach der OLG-Hamm-Rechtsprechung (Az. I-4 UKI 3/25) zur Haftung bei KI-Outputs ein neuer und nicht trivialer Posten, der 2026/27 erst seinen endgueltigen

Marktpreis findet. Die BSI-Audit-Anteile fallen ohnehin an, sobald die Plattform produktiv eingesetzt wird, daher kein Mehraufwand fuer KI spezifisch.

4. Cloud-Begleitkosten (oft unterschlagen)

Wer Cloud-Token-Pricing direkt mit Onpremise-Kosten vergleicht, vergleicht Äpfel mit Birnen. Auch fuer die Cloud-Nutzung wird eine produktive Infrastruktur benoetigt, deren Kosten in keinem Anbieter-Preisblatt auftauchen. Die folgende Aufstellung macht diese Kosten transparent.

Position (EUR pro Jahr)	EU-Cloud	EU-Region US-Anbieter	US-Cloud
Site-to-Site VPN / Private Link	4.000	5.500	5.500
API Gateway (Kong/Tyk, Auth, Rate Limit)	2.500	2.500	2.500
Auth / SSO-Integration anteilig	1.000	1.000	1.000
LLM-Observability (Langfuse self-hosted)	3.500	3.500	3.500
Audit-Trail-Storage (DSGVO Art. 30, 10 J.)	1.200	1.500	1.500
TLS / Secret Management (Vault anteilig)	1.000	1.000	1.000
Multi-Vendor-Abstraktion (LiteLLM)	1.500	1.500	1.500
FinOps / Token-Budget-Monitoring	2.000	2.500	2.500
Provider-Compliance-Audit (BSI C5)	2.500	4.500	4.500
DPO / Legal Review (AV-Vertrag)	3.000	6.000	6.000
Drittlandtransfer-TIA (US-Anbieter)	0	4.000	4.000
Cyber- / DSGVO-Versicherung Cloud-Anteil	2.500	4.000	4.000
KI-Haftpflicht (gleich wie Onpremise)	3.000	3.000	3.000
Personal Cloud-/Vendor-Ops (0,15 FTE)	13.500	13.500	13.500
Personal Compliance / DSB-Anteil	4.500	6.000	6.000
Netzwerk-Bandbreite Upgrade	1.200	1.200	1.200
Migration und Konfiguration (3J. AfA)	10.000	12.000	12.000
Summe Cloud-Infrastruktur p.a.	56.900	73.200	73.200

Wichtig: Diese 56.900 bis 73.200 EUR fallen *zusaetzlich* zu den reinen Tokengebuehren an und sind unabhaengig vom Volumen weitestgehend fix. Auch ein hybrider Ansatz mit Cloud-Token-Bezug benoetigt diese Infrastruktur. Der haeufig gehoerte Cloud-Vorteil "wir sparen das Personal" ist eine optische Taeuschung: Die Arbeit wechselt nur die Farbe, vom GPU-Patching zum Vendor-Management, von vLLM-Updates zur FinOps-Pflege.

5. TCO-Hauptvergleich

Die folgende Tabelle zeigt die Total Cost of Ownership pro Jahr bei der Annahme einer 70-Prozent-sustained-Auslastung der Plattform. Diese entspricht einem realistischen Mischbetrieb aus mehreren Anwendungen, etwa Arztbrief-Erstellung, Krankenkassen-Analytik, Forschungsauswertung, Diktat-Transkription und naechentlichen Batch-Pipelines fuer Embeddings und Vorberechnungen.

Option	Token p.a.	Infrastruktur	TOTAL p.a.	EUR / Mio. Tok	3 Jahre kumuliert
Onpremise Mittel-RZ (ISO 27001)	-	97.417	97.417	0,153	292.252
Onpremise Premium-RZ (BSI C5)	-	118.157	118.157	0,186	354.472
Onpremise KRITIS-RZ (georedundant)	-	142.397	142.397	0,224	427.192
DeepInfra (US, nicht zulaessig)	47.047	73.200	120.247	0,189	360.740
Parasail (US, nicht zulaessig)	70.570	73.200	143.770	0,226	431.310
Together.ai (US, nicht zulaessig)	139.868	73.200	213.068	0,335	639.205
Vertex AI EU-Region (Cloud Act)	222.518	73.200	295.718	0,465	887.154
STACKIT AI Model Serving (DE)	413.248	56.900	470.148	0,739	1.410.443
IONOS AI Model Hub (DE)	445.036	56.900	501.936	0,789	1.505.808
OVHcloud AI Endpoints (FR/DE)	508.613	56.900	565.513	0,889	1.696.538

Einsparungen Onpremise versus Cloud

Vergleich	Einsparung p.a.	3 Jahre	Faktor
KRITIS-Onpremise vs. STACKIT	327.751	983.252	3,30x
KRITIS-Onpremise vs. IONOS	359.539	1.078.617	3,53x
KRITIS-Onpremise vs. OVHcloud	423.116	1.269.347	3,97x
KRITIS-Onpremise vs. Vertex AI EU	153.321	459.963	2,08x
Mittel-RZ-Onpremise vs. STACKIT	372.731	1.118.192	4,83x

Lesart: Onpremise-Kosten sind fix und unabhaengig vom Volumen. Cloud-Kosten skalieren linear. Bei steigender Auslastung wird der relative Vorteil von Onpremise immer groesser. Bei sinkender Auslastung kehrt sich das Verhaeltnis um, siehe naechster Abschnitt zur Break-Even-Analyse.

6. Break-Even-Analyse

Die Break-Even-Analyse beantwortet die Frage, ab welchem Tokenvolumen sich die KRITIS-Onpremise-Loesung gegenueber einer Cloud-Alternative lohnt. Da Onpremise-Kosten fix und Cloud-Kosten variabel sind, gibt es einen klar definierten Umschlagspunkt.

Cloud-Anbieter	Tokenpreis EUR/Mio.	Break-Even Volumen	Entsprechende Auslastung
DeepInfra (US, nicht zulaessig)	0,074	935,1 Mrd. Tok/a	102,9 Prozent
Together.ai (US, nicht zulaessig)	0,220	314,5 Mrd. Tok/a	34,6 Prozent
Vertex AI EU-Region	0,350	197,7 Mrd. Tok/a	21,8 Prozent
STACKIT (DE)	0,650	131,5 Mrd. Tok/a	14,5 Prozent
IONOS (DE)	0,700	122,1 Mrd. Tok/a	13,4 Prozent
OVHcloud (FR/DE)	0,800	106,9 Mrd. Tok/a	11,8 Prozent

Interpretation: Gegenueber den deutschen souverainen Anbietern STACKIT und IONOS lohnt sich KRITIS-Onpremise bereits ab rund 13 bis 15 Prozent Auslastung. Das ist ein Wert, der mit einer einzigen produktiven Anwendung leicht erreicht wird. Gegenueber Vertex AI EU liegt der Break-Even bei 22 Prozent Auslastung. Der vermeintlich billige US-Anbieter DeepInfra waere theoretisch erst bei 103 Prozent Auslastung guenstiger, also nie. Hinzu kommt: Beide US-Anbieter sind fuer Klinikdaten nicht zulaessig.

TCO bei verschiedenen Volumina

Volumen Mrd. Tok/a	Onpremise KRITIS	STACKIT	Vertex AI EU	DeepInfra
25 (sehr klein)	142.397	73.150	81.950	75.050
100 (moderat)	142.397	121.900	108.200	80.600
200 (gross)	142.397	186.900	143.200	88.000
450 (sehr gross)	142.397	349.400	230.700	106.500
636 (Annahme 70 Prozent)	142.397	470.148	295.718	120.247
800 (Multi-Tenant)	142.397	576.900	353.200	132.400

7. Validierung und Grenzen der Analyse

Was diese Analyse validiert

Alle 241 Formeln des zugrundeliegenden Modells wurden gegen die erwarteten Werte gegengerechnet. Alle internen Konsistenzprüfungen sind bestanden: Hardware-CapEx, AfA-Berechnung, Stromverbrauch, Durchsatz-Berechnung, Summierung der RZ-Posten, Summierung der Cloud-Infrastruktur und alle TCO-Endwerte stimmen mit den unabhängig nachgerechneten Ergebnissen überein.

Sensitivitäten

- **Strompreis:** Auch bei einem Anstieg auf 0,40 EUR/kWh verschiebt sich die Onpremise-TCO nur um rund 4.700 EUR pro Jahr. Der relative Vorteil gegenüber EU-Cloud bleibt erhalten.
- **Auslastung:** Im Bereich 50 bis 90 Prozent bleibt der Onpremise-Vorteil gegenüber EU-Cloud deutlich. Unterhalb von 15 Prozent kippt der Vergleich gegenüber STACKIT, was die Notwendigkeit der Workload-Konsolidierung unterstreicht.
- **Personalkosten:** Eine Erhöhung der Plattform-Ops von 0,2 auf 0,3 FTE addiert 9.000 EUR pro Jahr. Auch das ändert die qualitative Aussage nicht.
- **Server-Hardware:** Bei einer konservativeren Annahme von 40.000 EUR statt 32.000 EUR für den GPU-Tragerserver addiert sich die AfA um rund 2.700 EUR pro Jahr.
- **Tokenpreise:** Die EU-Anbieter sind als Proxy modelliert, da Gemma 4 31B Stand Mai 2026 dort noch nicht explizit gelistet ist. Bei 30 Prozent niedrigeren Tokenpreisen liegt der Break-Even-Punkt immer noch bei rund 20 Prozent Auslastung.

Bekannte Grenzen

- Die Tokenpreise der EU-Anbieter wurden aus vergleichbaren Modellen (Llama 3.3 70B, Mistral Large) abgeleitet, da Gemma 4 31B noch nicht im Standardkatalog gelistet ist. Reale Preise können um 20 bis 30 Prozent abweichen.
- Die Cluster-Peak-Durchsatzangabe von 28.800 Tokens pro Sekunde basiert auf Hersteller-Benchmarks mit NVFP4-Quantisierung und Multi-Token-Prediction. Reale Werte können je nach Anwendungsmix um 10 bis 20 Prozent variieren.
- Eine 70-Prozent-sustained-Auslastung setzt strukturelle Workload-Konsolidierung voraus. Sie ist nicht mit einer einzelnen Anwendung erreichbar, sondern verlangt mehrere parallele Use Cases oder Mandanten.
- Die KI-Haftpflichtversicherung ist nach OLG-Hamm-Rechtsprechung ein neuer Posten, dessen Marktpreise sich 2026/27 erst stabilisieren. Die Schätzungen von 3.000 bis 8.000 EUR pro Jahr basieren auf ersten Angeboten und können sich ändern.
- Personalkosten sind mit Vollkostensatz von 90.000 EUR/FTE angesetzt. Bei Externen oder höher qualifiziertem Personal liegt dieser Wert höher.

Methodische Klarstellung: Diese Analyse ist eine entscheidungsorientierte Kostenmodellierung, kein Festpreis-Angebot. Sie liefert die Grundlage für eine fundierte Strategieentscheidung. Konkrete Implementierungspreise hängen vom gewählten RZ-Partner, dem Beschaffungszeitpunkt und der Vertragsausgestaltung ab.

8. Strategische Schlussfolgerungen

Wirtschaftliche Ebene

Bei produktiver Auslastung ist die souveräne Onpremise-Plattform die wirtschaftlich klar bessere Option. Sie schlägt die deutschen Cloud-Anbieter um den Faktor 3 bis 5 und unterbietet selbst die günstigsten US-Anbieter knapp, ohne deren rechtliche Risiken zu tragen. Über drei Jahre kumuliert spart die Lösung gegenüber STACKIT rund 983.000 EUR. Das finanziert exakt die nächste Generation Grafikkarten im Jahr 2029 und damit die langfristige Plattformfähigkeit.

Regulatorische Ebene

Für die Verarbeitung von Patienten- und Versichertendaten ist die Auswahl ohnehin enger als oft dargestellt. Die direkten Schnittstellen der grossen US-Sprachmodelle sind nicht zulässig. Anbieter mit US-Mutterkonzern unterliegen dem Cloud Act. Die souveränen europäischen Anbieter sind regulatorisch tauglich, aber teuer. Damit verbleiben als ernsthafte Optionen die EU-Cloud-Anbieter und der eigene Betrieb. Wirtschaftlich gewinnt der eigene Betrieb deutlich.

Strategische Ebene

Der eigentliche Hebel liegt in der Workload-Konsolidierung. Wer eine KI-Plattform nicht als Speziallösung für einen Anwendungsfall, sondern als gemeinsame Infrastruktur für mehrere Anwendungen (Arztbrief-Generierung, Krankenkassen-Analytik, Forschungsauswertung, Diktat-Transkription) und gegebenenfalls mehrere Mandanten oder Standorte konzipiert, erreicht die wirtschaftliche Wirksamkeit. Die Plattform wird damit zu einem strategischen Asset, nicht zu einem isolierten Projekt.

Investitionsstau als versteckter Treiber

Viele Cloud-Wechsel im Gesundheitswesen sind nicht rational mit Tokenpreisen begründet, sondern mit einem aufgestauten Modernisierungsbedarf der Basis-IT. Server stehen vor End-of-Life, Stromversorgung trägt keine modernen Hochleistungs-Racks, Netzwerk-Infrastruktur ist Legacy, Skills für Plattform-Operations fehlen. Wer in dieser Situation KI ins Haus holen will, sieht nicht 200.000 EUR für KI-Hardware, sondern eine halbe Million EUR für die Modernisierung der gesamten Basis. Cloud wirkt deshalb attraktiv, weil sie nur die KI-Schicht entscheidet und die unangenehme Modernisierungsfrage scheinbar umgeht.

Das Problem an dieser Logik: Der Investitionsstau verschwindet nicht, sondern wird verschoben. Die alte Hardware veraltet weiter, das Netzwerk muss spätestens für die sichere Cloud-Anbindung modernisiert werden, in fünf Jahren steht das Haus vor einer noch grösseren Welle. Bei Einrichtungen unter der KRITIS-Regulierung wird die Basis-Modernisierung in den kommenden zwei bis drei Jahren ohnehin gesetzlich erzwungen.

Ausblick: KI als Grundlage künftiger Softwareentwicklung

Software wird in den kommenden fünf Jahren in wachsendem Masse von KI geschrieben und im Betrieb auch von KI gesteuert. Wer heute eigene Rechenleistung für KI im Haus aufbaut, beantwortet damit nicht nur eine einzelne Fachfrage, sondern schafft die Grundlage dafür, wie Anwendungen in der eigenen Organisation künftig entstehen und laufen. Für Häuser, die ihre kritischen Systeme im eigenen Rechenzentrum betreiben, ist die souveräne KI-Plattform der notwendige Einstieg in das KI-Zeitalter.

Empfehlung: Die KI-Investition als strategischen Hebel nutzen, um die ohnehin faellige Basis-Modernisierung strukturiert abzuarbeiten. Damit entsteht aus einer scheinbaren Doppelinvestition ein integrierter Modernisierungspfad mit klarer Kosteneinsparung gegenueber dem Cloud-Wechsel.